

MEMORIA DEL TRABAJO FIN DE MÁSTER

ANÁLISIS DE DATOS

Marketing Analytics para Empresa Fintech

Trabajo Final de Máster
Nuclio Digital School

Autores:

Jesús José Zapata Seijas

Diego Perales

Lizbeth Hernández Sánchez

Lucía Moreno Guirado

Mónica Romero García

Abril 2026

ÍNDICE

1. Introducción y Contexto	3
2. Metodología y Herramientas	3
3. Descripción del Dataset.....	5
3.1 Clasificación de Variables	5
3.2 Calidad Inicial del Dataset	6
4. Preparación de Datos	6
4.1 Función de Limpieza (limpieza_fintech).....	6
4.2 Ingeniería de Características	7
5. Estadísticas Descriptivas.....	8
5.1 Variables Numéricas.....	8
5.2 Variables Categóricas.....	9
5.3 Detección de Outliers	11
5.4 Variable Target: Suscripción al Depósito	12
5.5 Correlaciones y Multicolinealidad	12
6. Relación Demográfica–Suscripción.....	13
6.1 Edad	13
6.2 Tipo de Trabajo	14
6.3 Nivel Educativo.....	16
6.4 Estado Civil	17
6.5 Crédito en Incumplimiento	17
6.6 Hipoteca y Préstamo Personal	17
7. Impacto de la Campaña en la Suscripción.....	18
7.1 Número de Contactos y Punto de Saturación.....	18
7.2 Mes y Día del Contacto.....	19
7.3 Duración de la llamada.....	20
7.4 Método de Contacto	21
7.5 Historial de Campañas Anteriores.....	22
7.6 Variables Macroeconómicas	23
8. Tasas de Éxito entre Perfiles de Clientes.....	25
9. Indicadores del Éxito de la Campaña.....	26
10. Resumen de Hallazgos y Ranking de Factores.....	28
11. Conclusiones y Recomendaciones Estratégicas.....	29

Conclusiones:	29
Recomendaciones Estratégicas:.....	30
12. Modelado Predictivo Simple.....	31
12.1 Objetivo y Enfoque Metodológico.....	31
12.2 Preparación de Datos para el Modelo	32
12.3 Estrategia de Validación: Nested Cross-Validation	33
12.4 Espacio de Hiperparámetros	33
12.5 Experimento 1: Línea Base sin Balanceo	34
12.6 Experimento 2: Submuestreo de la Clase Mayoritaria	36
12.7 Análisis Comparativo de Experimentos	39
12.8 Evaluación del Modelo.....	41
12.9 Conclusiones del Modelado Predictivo	41
12.10. Herramienta de predicción de suscripción	42
13. Dashboard	43
13.1. Definición de KPIs.....	43
13.2. Estructura del dashboard.....	43
13.3. Diseño e implementación del Dashboard	44
13.4. Visualizaciones	45
13.5. Conclusiones y recomendaciones	50
13.5.1. Conclusiones	50
13.5.2. Recomendaciones estratégicas	51
ANEXO 1: ÍNDICE DE FIGURAS.....	54
ANEXO 2: ÍNDICE DE TABLAS	56

1. Introducción y Contexto

Este informe documenta los pasos que se han realizado a lo largo del trabajo y los resultados del análisis exhaustivo de datos del Trabajo Final de Máster en Marketing Analytics para una empresa Fintech.

El objetivo principal es analizar los datos de campañas de marketing directo, realizadas mediante llamadas telefónicas de un banco portugués entre mayo de 2018 y noviembre de 2020, con el fin de:

- Entender la naturaleza, distribución y calidad de los datos de clientes y campañas.
- Identificar patrones, tendencias y factores que influyen en la contratación de un depósito a plazo.
- Comparar tasas de éxito entre diferentes tipos y perfiles de clientes.
- Evaluar posibles indicadores del éxito de la campaña, como la duración de la llamada.

Este análisis sienta las bases para las tareas posteriores del TFM: modelado predictivo (Tarea 3), dashboard ejecutivo (Tarea 4) y recomendaciones estratégicas (Tarea 5).

2. Metodología y Herramientas

El análisis se desarrolló íntegramente en Python mediante un notebook de Jupyter (tarea_1_notebook.ipynb), siguiendo un flujo estructurado en tres etapas: exploración, limpieza y análisis bivariable.

Stack Tecnológico:

Tabla 1. Stack tecnológico usado en el notebook 1 para la limpieza y exploración de los datos.

Librería	Versión	Uso en el Proyecto
pandas	≥ 2.0	Manipulación y análisis de datos tabulares
numpy	≥ 1.24	Operaciones numéricas y arrays (dependencia core de pandas y matplotlib)
matplotlib	≥ 3.7	Visualización estática (histogramas, boxplots, barplots)
		Visualización estadística avanzada (violinplots, KDE,

seaborn	≥ 0.12	barplots)
missingno	≥ 0.5	Análisis visual de valores nulos, utilizada internamente por la función <code>exploracion_inicial()</code> de la librería personalizada (celda 6)

Librería Personalizada:

Se utilizó el módulo “funciones_limpieza_y_analisis.py”, una librería desarrollada durante el curso que centraliza funciones de exploración y limpieza de datos. Este módulo fue importado en el notebook (celda 2) como “mi_biblioteca”. De las tres funciones disponibles en la librería, se utilizaron las siguientes en el notebook:

- **exploracion_inicial(df):** Ejecutada en la celda 6 del notebook sobre el DataFrame crudo. Genera un análisis completo que incluye: dimensiones del DataFrame, tipos de datos, head/tail/sample, estadísticas descriptivas (numéricas y categóricas), análisis de nulos con visualizaciones missingno (bar, matrix, heatmap), y conteo de duplicados.
- **limpieza_fintech(df):** Pipeline de limpieza específico para este dataset. Esta función fue redefinida localmente en la celda 7 del notebook, ampliándola con tres pasos adicionales respecto a la versión de la librería: (7) agrupación de `previously_contacted` en intervalos temporales (`days_since_last_contact_group`), (8) eliminación de la columna original `previously_contacted`, y (9) reordenación de las columnas del DataFrame para mejor visualización.
- **Nota:** La librería también contiene la función `leer_archivo(ruta)` para lectura universal de archivos CSV/Excel, que no fue utilizada en este análisis; la carga de datos se realizó directamente con `pd.read_csv()`.

Técnicas de Análisis:

- **Análisis univariable:** Histogramas con KDE (kernel density estimation) y línea de media para variables numéricas; gráficos de barras para distribuciones categóricas; boxplots horizontales para variables macroeconómicas.
- **Análisis bivariable:** Cálculo de tasas de conversión (`success_rate`) mediante `groupby().mean()` sobre la variable objetivo codificada numéricamente (`subscribed_num`). Gráficos de barras por segmento.
- **Violin plots:** Para comparar distribuciones de variables macroeconómicas entre suscriptores y no suscriptores, con cuartiles integrados (`inner="quartile"`).
- **Tablas de contingencia:** Crosstabs normalizados (`pd.crosstab` con `normalize=True`) para analizar la distribución conjunta de variables categóricas con la suscripción.

3. Descripción del Dataset

El dataset bank-additional-full.csv contiene 41.188 registros y 21 variables, separadas por punto y coma (;). Los registros están ordenados cronológicamente, cubriendo el periodo de mayo de 2018 a noviembre de 2020.

3.1 Clasificación de Variables

Tabla 2. Clasificación de las variables del dataset.

Tipo	Cantidad	Variables
Numéricas	10	age, duration, campaign, pdays, previous, emp.var.rate, cons.price.idx, cons.conf.idx, euribor3m, nr.employed
Categorías	10	job, marital, education, default, housing, loan, contact, month, day_of_week, poutcome
Target (binaria)	1	y (yes/no)

Las variables se organizan en cinco bloques temáticos:

- **Demográficas:** edad, tipo de trabajo, estado civil, nivel educativo.
- **Financieras:** crédito en incumplimiento (default), hipoteca, préstamo personal.
- **Contacto:** método de contacto, mes y día del último contacto, duración de la llamada.
- **Campaña:** número de contactos realizados, historial de campañas anteriores, días desde último contacto.
- **Macroeconómicas:** tasa de variación del empleo, Euribor a 3 meses, IPC, confianza del consumidor, total de empleados.

3.2 Calidad Inicial del Dataset

Tabla 3. Métricas observadas y sus resultados.

Métrica	Resultado
Valores nulos (NaN)	0, No hay datos faltantes en formato NaN
Filas duplicadas	12 de 41.188 (0.03%)
Valores "unknown"	Presentes en 6 variables: job, marital, education, default, housing, loan
Códigos especiales	pdays=999 en el 96.3% de registros, indica "nunca contactado previamente"
Registros con duration=0	4 registros, llamadas no conectadas

La exploración inicial se realizó mediante la función `exploracion_inicial()` de la librería personalizada, que generó un análisis detallado de dimensiones, tipos, distribuciones, nulos y duplicados.

4. Preparación de Datos

4.1 Función de Limpieza (limpieza_fintech)

Se implementó la función `limpieza_fintech()` para ejecutar un pipeline de limpieza reproducible sobre el dataset original. El resultado es un DataFrame limpio de 40.186 registros. Los pasos ejecutados son:

Paso 1: Renombrado técnico de columnas:

Se tradujeron y clarificaron los nombres de las 19 columnas principales para mejorar la legibilidad del análisis. Ejemplos: `job` → `job_type`, `y` → `subscribed`, `duration` → `call_duration`, `euribor3m` → `euribor_3m_rate`, `nr.employed` → `total_employment`.

Paso 2: Tratamiento de unknowns:

Los valores "unknown" en las variables `job_type`, `marital_status`, `education_level` y `credit_default` fueron reemplazados por "undisclosed" para mantener la semántica sin eliminar registros.

Paso 3: Eliminación de duplicados:

Se eliminaron 12 filas duplicadas exactas (excluyendo la variable objetivo), reduciendo el dataset de 41.188 a 41.176 registros.

Paso 4: Categorización de duración:

La variable `call_duration` fue agrupada en 6 intervalos significativos mediante `pd.cut(right=True)`:

Tabla 4. Categorización de la duración de la llamada.

Grupo	Rango (segundos)
0-1 min	(-1, 60]
2-3 min	(60, 180]
4-5 min	(180, 300]
6-10 min	(300, 600]
11-20 min	(600, 1200]
21+ min	(1200, 10000]

Paso 5: Variables categóricas ordenadas:

Los meses (mar→dec) y días de la semana (mon→fri) fueron convertidos a `pd.Categorical` con orden cronológico para asegurar la secuencia correcta en gráficos y análisis.

Paso 6: Eliminación de unknowns residuales:

Se eliminaron 990 registros con valores "unknown" en `has_housing_loan` y `has_personal_loan`, reduciendo el dataset de 41.176 a 40.186 registros. Estas variables no fueron renombradas a "undisclosed" porque la proporción era muy baja y la decisión del equipo fue eliminarlas para garantizar datos limpios en el análisis financiero.

4.2 Ingeniería de Características

Se crearon dos variables derivadas a partir de las existentes:

Tabla 5. Nuevas variables creadas a partir de las existentes.

Variable	Lógica	Propósito
<code>is_new_campaign_client</code>	<code>previous_contacts == 0 → "yes", else "no"</code>	Identificar clientes que participan por primera vez en una campaña
<code>high_contact_attempts</code>	<code>contact_attempts > 3 → "yes", else "no"</code>	Detectar saturación del cliente (umbral en 3 contactos)

Finalmente, la columna "subscribed" fue reordenada al final del DataFrame para facilitar la lectura y el análisis posterior.

5. Estadísticas Descriptivas

Esta sección presenta las características básicas de los datos del dataset limpio (40.186 registros), analizadas mediante histogramas con KDE, boxplots y gráficos de distribución.

5.1 Variables Numéricas

Se generaron histogramas con estimación de densidad por kernel (KDE) y líneas de media para age y call_duration (celda 11 del notebook), y boxplots horizontales para las 5 variables macroeconómicas (celda 13). Los histogramas incluyen líneas de media (rojo) y la estimación de densidad KDE superpuesta.




Figura 1. Distribución de edad y duración de llamada con estimación de densidad (KDE), líneas de media y mediana.

Tabla 6. Descripción estadística de las variables numéricas del dataset.

Variable	Media	Mediana	Desv.Est	Mín	Máx
age	40.03	38.0	10.42	17	98
call_duration	258.52	180.0	259.41	0	4.918
contact_attempts	2.57	2.0	2.77	1	43
previously_contacted	962.40	999.0	187.08	0	999
previous_contacts	0.17	0.0	0.49	0	7
employment_variation_rate	0.08	1.1	1.57	-3.4	1.4

consumer_price_index	93.57	93.75	0.58	92.20	94.77
consumer_confidence_index	-40.51	-41.8	4.63	-50.8	-26.9
euribor_3m_rate	3.62	4.86	1.73	0.63	5.04
total_employment	5.167	5.191	72.23	4.964	5.228

Observaciones clave:

- call_duration presenta extrema dispersión ($\sigma=259$, rango 0-4.918 seg). Su histograma muestra una distribución fuertemente sesgada a la derecha.
- contact_attempts tiene la mayoría de los clientes contactados 1-3 veces, pero con un máximo de 43 intentos.
- previously_contacted concentra el 96.3% en 999 (nunca contactado), generando una distribución bimodal artificial.
- Las variables macroeconómicas muestran distribuciones peculiares: euribor_3m_rate y employment_variation_rate tienen distribuciones bimodales, reflejando los ciclos económicos del periodo 2018-2020.

5.2 Variables Categóricas

Se generaron gráficos de barras para todas las variables categóricas (celda 14), iterando sobre `df_fintech_clean.select_dtypes(include='object').columns`, iterando sobre las columnas de tipo object:




Figura 2. Distribución de las principales variables categóricas del dataset limpio.

Tabla 7. Descripción estadística de las variables categóricas del dataset.

Variable	Categoría Dominante	% Dominante	Nº Categorías
job_type	admin.	25.4%	12
marital_status	married	60.5%	4
education_level	university.degree	29.6%	8
credit_default	no	79.2%	3
has_housing_loan	yes	53.7%	2
has_personal_loan	no	84.4%	2
contact_method	cellular	63.6%	2
previous_campaign_outcome	nonexistent	86.3%	3
is_new_campaign_client	yes	86.3%	2
high_contact_attempts	no	81.4%	2

Perfil promedio del cliente (dataset limpio): persona de ~40 años, casada, con estudios universitarios, sin crédito impago, trabajadora del sector administrativo, contactada por primera vez por celular.

5.3 Detección de Outliers

Los boxplots horizontales de las variables macroeconómicas (celda 13) revelaron que estas variables no presentan outliers clásicos, sino distribuciones condicionadas por los ciclos económicos del periodo. En las variables de campaña, los histogramas (celda 12) muestran concentración en valores bajos con colas largas en `contact_attempts` y `previously_contacted`.




Figura 3. Boxplots horizontales de las 5 variables macroeconómicas mostrando cuartiles y distribución.

5.4 Variable Target: Suscripción al Depósito

Tabla 8. Variable target del dataset.

Categoría	Registros	Porcentaje
no	35.654	88.72%
yes	4.532	11.28%

Desbalance de clases: La proporción es de 7.87:1 (no vs yes). Este desbalance severo deberá ser tratado en la fase de modelado predictivo (Tarea 3) mediante técnicas como SMOTE, `class_weight="balanced"`, o ajuste del threshold de decisión.




Figura 4. Distribución de la variable target (subscribed) mostrando el ratio de desbalance 7.87:1.

5.5 Correlaciones y Multicolinealidad

Pares de variables macroeconómicas con alta multicolinealidad ($|r| > 0.70$):




Figura 5. Matriz de correlación de Pearson para variables numéricas.

Tabla 9. Correlación de las variables macroeconómicas.

Variable 1	Variable 2	Correlación	Implicación
emp.var.rate	euribor3m	0.9723	Prácticamente la misma información
emp.var.rate	nr.employed	0.9069	Alta redundancia
euribor3m	nr.employed	0.9454	Alta redundancia

6. Relación Demográfica–Suscripción

Esta sección analiza la relación entre las características demográficas del cliente y la probabilidad de contratar el depósito. Se utilizaron boxplots (celda 16), cálculos de success_rate (celdas 18-25) y tablas de contingencia normalizadas (celdas 30-34).

6.1 Edad

El boxplot de edad vs suscripción (celda 16) muestra que los suscriptores tienen una distribución de edad más dispersa, con medianas similares pero mayor presencia en los extremos.




Figura 6. Boxplot de distribución de edad por resultado de suscripción.

Tabla 10. Relación entre la edad y la suscripción.

Banda Etaria	Registros	Conversión	vs. Media (11.28%)
< 30 años	7.206	15.21%	+3.93 pp
30-40 años	15.991	9.81%	-1.47 pp
41-50 años	9.982	8.13%	-3.15 pp
51-60 años	6.118	10.66%	-0.62 pp
60+ años	889	45.33%	+34.05 pp

El patrón muestra una curva en "U": los jóvenes (<30, 15.21%) y especialmente los mayores (60+, 45.33%) convierten muy por encima de la media, mientras que el rango central (30-50) tiene las tasas más bajas. Los mayores de 60 representan solo el 2.2% del dataset pero convierten casi 1 de cada 2.

6.2 Tipo de Trabajo

La tabla de contingencia normalizada (celda 33) y los success_rate revelan:




Figura 7. Tasa de conversión por tipo de trabajo, ordenada de menor a mayor. La línea roja discontinua indica la media global (11.28%).

Tabla 11. Relación entre el tipo de trabajo y la suscripción.

Trabajo	Registros	Conversión	Observación
student	852	30.99%	Top converter: jóvenes en formación
retired	1.674	25.33%	Segundo mejor: perfil con ahorros
unemployed	987	14.49%	Por encima de la media
admin.	10.192	12.97%	Grupo más grande, conversión media
undisclosed	325	11.38%	En línea con la media
blue-collar	9.013	6.90%	El peor conversor del dataset

Existe una brecha de 24 puntos porcentuales entre student (30.99%) y blue-collar (6.90%). Los estudiantes y jubilados, pese a representar un porcentaje minoritario, son los segmentos con mayor propensión a contratar.

6.3 Nivel Educativo

Tabla 12. Relación entre la educación y la suscripción.

Educación	Registros	Conversión	Observación
illiterate	18	22.22%	Muestra muy pequeña (n=18)
undisclosed	1.690	14.56%	Por encima de la media, perfil valioso
university.degree	11.887	13.75%	Grupo grande con buena conversión
professional.course	5.115	11.32%	En la media
high.school	9.292	10.87%	Ligeramente por debajo
basic.9y	5.894	7.80%	Baja conversión

Se observa una tendencia directa: a mayor nivel educativo, mayor probabilidad de contratación. Los universitarios lideran con 13.75%. Los clientes con educación undisclosed convierten 14.56%, confirmando que no son ruido.




Figura 8. Tasa de conversión por nivel educativo.

6.4 Estado Civil

Tabla 13. Relación entre el estado civil y la suscripción.

Estado Civil	Registros	Conversión
undisclosed	79	15.19%
single	11.284	14.01%
divorced	4.490	10.42%
married	24.333	10.15%

Los solteros (14.01%) muestran mayor predisposición que los casados (10.15%), posiblemente por mayor flexibilidad financiera. Crosstab normalizado generado en celda 34.

6.5 Crédito en Incumplimiento

Tabla 14. Relación entre el crédito de incumplimiento y la suscripción.

Default	Registros	Conversión	Observación
no	31.814	12.89%	Base normal
yes	3	0.0%	Solo 3 casos, todos "no"
undisclosed	8.369	5.16%	Menos de la mitad que "no"

Los clientes con credit_default=undisclosed (20.8% del dataset) convierten solo 5.16%, menos de la mitad que los clientes sin incumplimiento (12.89%). Este grupo, analizado mediante barplot de success_rate (celda 25), muestra un perfil conservador con aversión al riesgo financiero.

6.6 Hipoteca y Préstamo Personal

Tabla 15. Relación entre la hipoteca y préstamo personal y la suscripción.

Variable	Sí	No	Significativa
Hipoteca (has housing_loan)	11.62%	10.88%	Débil
Préstamo (has_personal_loan)	10.93%	11.34%	Débil

Las tablas de contingencia normalizadas (celdas 36-37) muestran que ni la hipoteca ni el préstamo personal son discriminadores clave para la suscripción. Las diferencias son mínimas (<1pp).

7. Impacto de la Campaña en la Suscripción

7.1 Número de Contactos y Punto de Saturación

El barplot de success_rate por contact_attempts (celda 19) y la variable derivada high_contact_attempts (celda 24) revelan una relación negativa clara:




Figura 9. Tasa de conversión por número de intentos de contacto.

El color verde (≤ 3 contactos) vs rojo (>3) evidencia el punto de saturación. La línea dorada marca el umbral en 3 contactos.

Tabla 16. Relación entre el número de contactos y la suscripción.

Contactos	Conversión	Observación
1	13.00%	Mejor resultado con primer contacto
2	11.48%	Caída de ~1.5pp
3	10.78%	Último nivel aceptable
4	9.59%	Rendimiento decreciente
5	7.51%	Rendimiento decreciente
>10	~5%	Contraproducente

La variable `high_contact_attempts` confirma el umbral: los clientes contactados ≤ 3 veces convierten al 12.17%, mientras que los contactados >3 veces bajan a 7.36%. Insistir más allá de 3 intentos es contraproducente.

7.2 Mes y Día del Contacto

Mes del contacto (crosstab normalizado):




Figura 10. Panel dual: (izq.) tasa de conversión por mes, (der.) volumen de contactos.

Tabla 17. Relación entre el mes de contacto y la suscripción.

Mes	Registros	Conversión	Patrón
Marzo	534	50.75%	Máxima conversión, bajo volumen
Diciembre	176	48.86%	Alta conversión, muy bajo volumen
Septiembre	554	44.58%	Alta conversión, bajo volumen
Octubre	697	43.90%	Alta conversión, bajo volumen
Abril	2.573	20.37%	Conversión moderada-alta
Mayo	13.417	6.47%	Máximo volumen, mínima conversión

El volumen de contactos es inversamente proporcional a la conversión. Mayo concentra el 33% de los contactos pero solo el 6.47% de conversión, sugiriendo una campaña masiva poco segmentada.

Día de la semana (crosstab normalizado):

Tabla 18. Relación entre el día de la semana de contacto y la suscripción.

Día	Registros	Conversión
Jueves	8.429	12.08%
Miércoles	7.937	11.77%
Martes	7.876	11.72%
Viernes	7.623	10.86%
Lunes	8.321	9.96%

El jueves es el mejor día (12.08%) y el lunes el peor (9.96%). La distribución es equitativa (~20% por día).




Figura 11. Tasa de conversión por día de la semana.

7.3 Duración de la llamada

La variable `call_duration` no se conoce antes de realizar la llamada, por lo que no puede ser utilizada como predictor en un modelo de producción. Sin embargo, el barplot de `success_rate` por `call_duration_group` revela que es el indicador más fuerte del interés del cliente.




Figura 12. Probabilidad de suscripción por grupo de duración de llamada.

Tabla 19. Relación entre la duración de la llamada y la suscripción.

Grupo	Registros	Conversión
0-1 min	4.182	0.02%
2-3 min	15.981	3.45%
4-5 min	9.072	10.22%
6-10 min	7.568	18.66%
11-20 min	2.885	45.96%
21+ min	498	63.25%

Las llamadas de más de 21 minutos resultan en contratación en 2 de cada 3 casos (63.25%). La relación es proporcional y directa.

7.4 Método de Contacto

Crosstab normalizado:

Tabla 20. Relación entre el método de contacto y la suscripción.

Método	Registros	Conversión	Factor
Celular	25.574	14.70%	Referencia
Teléfono fijo	14.612	5.28%	2.8× peor

El celular convierte 2.8 veces más que el teléfono fijo.

7.5 Historial de Campañas Anteriores

Barplot de success_rate por previous_campaign_outcome:




Figura 13. Tasa de conversión por resultado de la campaña anterior.

Tabla 21. Relación entre el resultado de la campaña previa y la suscripción.

Resultado Previo	Registros	Conversión	Observación
success	1.345	64.91%	Mejor predictor del dataset
failure	4.141	14.05%	Por encima de la media
nonexistent	34.700	8.87%	No hubo campaña previa

Barplots complementarios:

Tabla 22. Relación entre si es un nuevo cliente o no y la suscripción.

Variable	Valor	Conversión
is new campaign client	no (recurrente)	26.52%
is new campaign client	yes (nuevo)	8.87%

Los clientes con resultado exitoso en una campaña anterior tienen 64.91% de conversión. Los clientes recurrentes (no nuevos) convierten 3× más que los nuevos (26.52% vs 8.87%). La experiencia previa positiva es el factor más determinante del dataset.




Figura 14. Comparación de la tasa de conversión entre clientes nuevos y los recurrentes.

7.6 Variables Macroeconómicas

Se generaron violin plots con cuartiles integrados (inner="quartile") para las 5 variables macroeconómicas vs subscribed:




Figura 15. Violin plots de las 5 variables macroeconómicas vs suscripción.

Tabla 23. Relación entre las variables macroeconómicas y la suscripción.

Variable	Media (yes)	Media (no)	Interpretación
employment_variation_rate	-1.23	+0.25	Suscripciones aumentan cuando el empleo disminuye
consumer_price_index	93.35	93.60	Efecto débil
consumer_confidence_index	-39.79	-40.60	Efecto muy débil
euribor_3m_rate	2.13	3.81	Suscripciones aumentan cuando el euribor disminuye
total_employment	5.095	5.176	Suscripciones aumentan con menos empleo

Los violin plots revelan que los suscriptores se concentran en periodos de euribor bajo y empleo en descenso. Los depósitos a plazo actúan como refugio seguro en contextos de incertidumbre económica.

8. Tasas de Éxito entre Perfiles de Clientes

El análisis bivariante del notebook (celdas 18-28) y las tablas de contingencia normalizadas (celdas 33-40) permiten comparar las tasas de éxito entre diferentes segmentos de clientes, identificando perfiles de alta y baja conversión.

Segmentos de Alta Conversión:

Tabla 24. Segmentos de alta conversión.

Perfil del Cliente	Tasa de Conversión	n	Insight
poutcome = success	64.91%	1.345	Cliente con éxito previo, máximo predictor
Edad > 60 años	45.33%	889	Alta disposición al ahorro conservador
Estudiantes	30.99%	852	Jóvenes receptivos a primeros productos financieros
Jubilados	25.33%	1.674	Perfil con ahorros y aversión al riesgo
Cliente recurrente	26.52%	5.486	La familiaridad con la marca impulsa la conversión
Solteros	14.01%	11.284	Mayor flexibilidad financiera
Celular	14.70%	25.574	Canal preferido y más efectivo
Universitarios	13.75%	11.887	Mayor acceso e interés en productos financieros

Segmentos de Bajo Rendimiento:

Tabla 25. Segmentos de bajo rendimiento.

Perfil del Cliente	Tasa de Conversión	n	Insight
blue-collar	6.90%	9.013	Trabajadores manuales, baja propensión
Contactados en mayo	6.47%	13.417	Campaña masiva poco segmentada
credit_default = undisclosed	5.16%	8.369	Sin historial crediticio, perfil conservador
Teléfono fijo	5.28%	14.612	Canal menos efectivo
Contactados >3 veces	7.36%	7.461	Saturación contraproducente
Educación basic.9y	7.80%	5.894	Menor interés en productos financieros

Volumen vs eficiencia:

Las tablas de contingencia normalizadas (pd.crosstab con normalize=True, multiplicado por 100) revelan que los sectores con mayor volumen de contactos (admin., blue-collar, casados) no son los más eficientes. Los estudiantes y jubilados, que representan segmentos pequeños, tienen tasas de conversión 3-4× superiores a la media.

Impacto de variables financieras:

Los crosstabs de housing_loan (celda 36) y personal_loan (celda 37) confirman que estas variables no son discriminadores significativos: las diferencias de conversión son inferiores a 1 punto porcentual. La decisión de contratar un depósito no depende de la carga financiera existente del cliente.

9. Indicadores del Éxito de la Campaña

Se identificaron tres indicadores críticos que determinan el éxito de la campaña, analizados mediante los barplots de success_rate y los violin plots del notebook:

Indicador 1: La Duración de la Llamada (Post-facto):

El barplot de `success_rate` por `call_duration_group` (celda 18) es la visualización más contundente del notebook. Existe una relación proporcional directa y fuerte:

- **Llamadas < 1 min:** 0.02%, llamadas no efectivas, el agente no logra enganchar.
- **Llamadas 4-5 min:** 10.22%, punto de inflexión donde la conversión supera la media.
- **Llamadas 11-20 min:** 45.96%, casi 1 de cada 2 clientes contrata.
- **Llamadas 21+ min:** 63.25%, 2 de cada 3 clientes contrata.

Si bien `duration` no puede usarse como predictor a priori (solo se conoce tras la llamada), es un indicador valioso para evaluar la calidad de los scripts de venta y el engagement logrado por los agentes durante la conversación.

Indicador 2 — El Historial del Cliente (Predictor Principal):

Se analizan tres dimensiones del historial:

- **`poutcome = success`:** 64.91% de conversión. Los clientes que aceptaron en una campaña anterior convierten 7× más que los nuevos.
- **`is_new_campaign_client = no`:** 26.52% vs 8.87% de los nuevos. Los clientes recurrentes son tres veces más valiosos.
- **`previously_contacted ≠ 999`:** Los clientes con contacto previo reciente muestran tasas de conversión dramáticamente superiores.




Figura 16. Tasa de conversión por recencia del último contacto.

El historial del cliente es, sin discusión, el predictor más poderoso del dataset. Las campañas futuras deben priorizar la re-contactación de clientes exitosos antes de invertir en leads nuevos.

Indicador 3: El Contexto Macroeconómico:

Los violin plots con inner="quartile" permiten visualizar la distribución completa de cada variable macroeconómica para suscriptores vs no suscriptores:

- **Euribor bajo:** Los suscriptores se concentran en euribor_3m_rate ~2.13 vs 3.81 de los no suscriptores. En entornos de tipos bajos, los depósitos son más atractivos como refugio.
- **Empleo en descenso:** employment_variation_rate media de -1.23 para suscriptores vs +0.25 para no suscriptores. La incertidumbre laboral empuja al ahorro conservador.
- **Menor empleo total:** total_employment media 5.095k (yes) vs 5.176k (no).

El timing macroeconómico es un factor modulador clave: lanzar campañas en periodos de euribor bajo e incertidumbre laboral maximiza la receptividad del cliente.

10. Resumen de Hallazgos y Ranking de Factores

Factores ordenados por impacto en la conversión, consolidando todos los análisis del notebook:




Figura 17. Ranking consolidado de los 10 factores con mayor impacto en la conversión, clasificados por tipo.

Tabla 26. Ranking de factores.

#	Factor	Conversión	Tipo	Celda
1	poutcome = success	64.91%	Campaña (historial)	20
2	Edad > 60 años	45.33%	Demográfico	16
3	Duración > 21 min	63.25%	Indicador (post-facto)	18
4	Cliente recurrente (no nuevo)	26.52%	Campaña (historial)	21
5	job = student	30.99%	Demográfico	30
6	job = retired	25.33%	Demográfico	30
7	Euribor bajo + empleo bajo	Significativo	Macroeconómico	28
8	contact = celular	14.70%	Campaña (canal)	35
9	education = undisclosed	14.56%	Demográfico	32
10	contact_attempts ≤ 3	12.17%	Campaña (saturación)	22

Los factores de campaña (historial previo, canal de contacto, saturación) tienen mayor poder predictivo que los factores demográficos, lo que indica que la estrategia de ejecución de la campaña es más determinante que el perfil intrínseco del cliente.

11. Conclusiones y Recomendaciones Estratégicas

Conclusiones:

- El predictor más poderoso es el resultado de campañas anteriores: poutcome=success genera un 64.91% de conversión, 7 veces más que los clientes nuevos.

- El contexto macroeconómico modula significativamente la receptividad: los depósitos se contratan más en periodos de euribor bajo y empleo en descenso, funcionando como refugio seguro para el ahorro.
- Existe un punto de saturación claro en 3 contactos: más allá, la conversión cae de 12.17% a 7.36%.
- El canal celular convierte 2.8 veces más que el teléfono fijo (14.70% vs 5.28%).
- La duración de la llamada es el mejor indicador de interés del cliente: 63.25% de conversión en llamadas de 21+ minutos, pero no es utilizable como predictor a priori.
- Los estudiantes (30.99%) y jubilados (25.33%) son los segmentos con mayor propensión a contratar, pese a ser minority del dataset.
- Los mayores de 60 años muestran la conversión demográfica más alta (45.33%), aunque representan solo el 2.2% del dataset.
- Los valores "undisclosed" (ex-unknowns) no son ruido: credit_default=undisclosed tiene comportamiento estadísticamente diferenciado (5.16% vs 12.89%), confirmando que contienen información predictiva.
- El dataset presenta un desbalance de clases de 7.87:1 que deberá ser tratado en la fase de modelado.

Recomendaciones Estratégicas:

Con base en los hallazgos de las Tareas 1, 2 y 3, se formulan las siguientes recomendaciones para optimizar futuras campañas:

1. Priorizar clientes con historial exitoso:

Los clientes con poutcome=success convierten al 64.91%. Se recomienda crear una "lista dorada" de re-contactación prioritaria antes de invertir en leads nuevos.

2. Limitar a 3 intentos de contacto por cliente:

Después de 3 contactos, la conversión cae 5 puntos porcentuales. Se recomienda implementar una regla de negocio que limite los intentos y reasigne el esfuerzo a leads frescos.

3. Usar celular como canal preferido:

El celular convierte 2.8× más que el fijo. Reservar el teléfono fijo solo para clientes sin celular registrado.

4. Redistribuir el esfuerzo de mayo:

Mayo concentra el 33% de contactos con solo 6.47% de conversión. Redirigir parte de esa carga hacia septiembre, octubre y marzo (conversiones >40%).

5. Segmentar para estudiantes y jubilados:

Diseñar ofertas y scripts específicos para estos perfiles que convierten 3-4× por encima de la media.

6. Segmentar para mayores de 60:

Con 45.33% de conversión, este micro-segmento tiene el mayor potencial demográfico. Considerar campañas dedicadas con productos ajustados a su perfil de riesgo.

7. Aprovechar ciclos macroeconómicos:

Lanzar campañas agresivas de depósitos en periodos de euribor bajo e incertidumbre laboral, cuando los clientes buscan refugio seguro.

8. Formar a los agentes para extender conversaciones productivas:

Las llamadas más largas correlacionan con mayor éxito (63.25% en 21+ min). Invertir en scripts de venta que generen engagement y confianza desde los primeros minutos.

12. Modelado Predictivo Simple

12.1 Objetivo y Enfoque Metodológico

El objetivo de esta tarea es construir un modelo predictivo simple basado en Regresión Logística que permita estimar la probabilidad de que un cliente contrate un depósito a plazo, utilizando el dataset limpio analizado en las Tareas 1 y 2.

El enfoque metodológico adoptado prioriza el rigor estadístico mediante:

- Regresión Logística, elegida por su interpretabilidad, robustez ante datos con alta dimensionalidad (tras one-hot encoding), y capacidad de producir probabilidades calibradas para cada predicción.
- Nested Cross-Validation (5×3), un esquema avanzado que separa la optimización de hiperparámetros de la evaluación del rendimiento, evitando fugas de información y sobreajuste en la selección del modelo.
- Dos escenarios experimentales: un modelo sin tratamiento del desbalance (línea base) y un modelo con submuestreo de la clase mayoritaria.

Todos los análisis fueron implementados en Python mediante el notebook modelo_predictivo.ipynb, utilizando scikit-learn como framework de modelado. Las métricas de evaluación incluyen Accuracy, Precision, Recall, F1-Score y AUC-ROC, con énfasis particular

en Recall dado el contexto de negocio, en marketing, es preferible contactar clientes que no contratarán (falsos positivos) a perder clientes potenciales (falsos negativos).

12.2 Preparación de Datos para el Modelo

Exclusión de Variables con Riesgo de Data Leaking:

Antes de entrenar el modelo, se eliminaron las variables `call_duration` y `call_duration_group` del conjunto de datos. Aunque el análisis de Tareas 1 y 2 demostró que la duración de la llamada es el indicador más fuerte de suscripción (63.25% de conversión en llamadas de 21+ minutos), esta variable solo se conoce después de que la llamada ha finalizado. Incluirla como predictor constituiría data leaking, el modelo aprendería una relación que no puede explotar en tiempo de predicción, generando métricas infladas e inútiles para la toma de decisiones.

Codificación de Variables Categóricas (One-Hot Encoding):

Las variables categóricas del dataset (`job_type`, `marital_status`, `education_level`, `credit_default`, `has_housing_loan`, `has_personal_loan`, `contact_method`, `contact_month`, `contact_day`, `previous_campaign_outcome`, `is_new_campaign_client`, `high_contact_attempts`, `days_since_last_contact_group`) fueron transformadas mediante one-hot encoding (`pd.get_dummies`), creando variables binarias para cada categoría. La variable target (`subscribed`) fue mapeada numéricamente: no $\rightarrow$ 0, sí $\rightarrow$ 1.



Figura 18. Distribución de la variable target para modelado.

12.3 Estrategia de Validación: Nested Cross-Validation

Se adoptó un esquema de Nested Cross-Validation (CV anidada) como metodología de evaluación, una técnica avanzada que proporciona estimaciones no sesgadas del rendimiento del modelo al separar completamente dos procesos:

- **Bucle externo (5-Fold):** Divide el dataset en 5 particiones. En cada iteración, 4/5 del dataset se usan para entrenamiento y validación y 1/5 se reserva como test para la evaluación final.
- **Bucle interno (3-Fold):** Dentro de cada fold externo, se aplica un GridSearchCV con 3-Fold CV para encontrar la mejor combinación de hiperparámetros. El modelo ganador se re-entrena con todos los datos de entrenamiento del fold externo y se evalúa en el test.

Este esquema genera 5 estimaciones independientes del rendimiento, cada una sin contaminación del proceso de selección de hiperparámetros. Es superior a un simple train/test split o un CV simple con GridSearch, donde la selección de hiperparámetros y la evaluación comparten los mismos datos, produciendo métricas optimistas.




Figura 19. Esquema del proceso de Nested Cross-Validation.

12.4 Espacio de Hiperparámetros

Se definió un espacio de búsqueda conservador pero efectivo para la Regresión Logística, adaptado al solver liblinear que soporta ambas regularizaciones L1 y L2:

Tabla 27. Hiperparámetros utilizados.

Hiperparámetro	Valores Evaluados	Justificación
solver	liblinear	Soporta L1 y L2; eficiente para datasets medianos
penalty	L1 (Lasso), L2 (Ridge)	L1 realiza selección de variables; L2 reduce multicolinealidad
C	0.1, 1.0	Fuerza inversa de regularización: C bajo, más regularización

Se han evaluado un total de 4 combinaciones (2 penalizaciones $\times$ 2 valores de C), cada una validada en 3 folds internos, resultando en 12 entrenamientos por fold externo y 60 entrenamientos totales por experimento. La métrica de optimización interna fue AUC-ROC, elegida por ser independiente del umbral de decisión y robusta ante el desbalance de clases.

12.5 Experimento 1: Línea Base sin Balanceo

Configuración y Justificación:

El primer experimento evalúa el rendimiento del modelo sobre el dataset completo sin aplicar ninguna técnica de balanceo de clases. Con un ratio de 7.87:1 (35.654 registros de clase "no" frente a 4.532 de clase "sí").

Resultados por Fold:

Tabla 28. Resultados por fold del experimento 1.

Fold	Accuracy	Precision	Recall	F1-Score	AUC-ROC
1	0.8984	0.6654	0.2017	0.3096	0.8014
2	0.9024	0.6741	0.2343	0.3477	0.7846
3	0.8956	0.6609	0.2049	0.3128	0.7816
4	0.8995	0.6883	0.2191	0.3325	0.7800
5	0.9007	0.6604	0.2002	0.3072	0.7921
Media	0.8993	0.6698	0.2120	0.3220	0.7879

Desv. Est.	± 0.0016	± 0.0140	± 0.0078	± 0.0097	± 0.0084
------------	--------------	--------------	--------------	--------------	--------------

Hiperparámetros óptimos seleccionados por GridSearchCV:

Tabla 29. Hiperparámetros óptimos seleccionados por GridSearchCV del experimento 1.

Fold	C	Penalización	Solver
1	1.0	L2 (Ridge)	liblinear
2	0.1	L1 (Lasso)	liblinear
3	0.1	L2 (Ridge)	liblinear
4	0.1	L2 (Ridge)	liblinear
5	1.0	L1 (Lasso)	liblinear




Figura 20. Métricas de evaluación por fold para el Experimento 1 (sin balanceo).




Figura 21. Panel izquierdo: Matriz de del fold 1 Exp 1. Panel derecho: Curvas ROC del fold 1 Exp 1.

Análisis del Experimento 1:

- La Accuracy (% de predicciones correctas totales) de 89.98%: aunque esta métrica sea alta no significa que el modelo prediga bien, ya que al ser la mayoría de los datos “no”, es normal que el modelo prediga verdaderos negativos.
- La Precision (predicción de verdaderos positivos) de 68.06% indica que predice bastante bien los “sí”, pero esta alta precisión se logra a costa de ser muy conservador en sus predicciones positivas.
- El Recall (detección de positivos reales) de 20.94% es el hallazgo más crítico: de cada 100 positivos solo detecta 21, por lo que se está perdiendo la mayoría de los casos positivos.
- El F1-score (balance entre precisión y recall) de 32.24% es bajo debido a que el recall es bajo.
- El AUC-ROC (como de bien separa las clases) de 0.7869 confirma que el modelo tiene capacidad discriminativa moderada, pero el umbral de decisión por defecto (0.5) es inadecuado para el desbalance existente.

El desbalance de 7.87:1 provoca que el modelo optimice la predicción de la clase mayoritaria, ignorando la minoritaria. En un contexto de marketing, esta configuración es inaceptable, perder 4 de cada 5 clientes potenciales tiene un coste de oportunidad mucho mayor que contactar algunos falsos positivos.

12.6 Experimento 2: Submuestreo de la Clase Mayoritaria

Estrategia de Balanceo:

Para mitigar el sesgo hacia la clase mayoritaria, se aplicó una técnica de submuestreo aleatorio, se redujo la clase "no" de 35.654 a 7.000 registros mediante muestreo aleatorio (random_state=1),

manteniendo intactos los 4.532 registros de la clase "sí". El dataset resultante contiene 11.532 registros con un ratio balanceado de 1.54:1, mucho más manejable para el modelo.




Figura 22. Comparación de la distribución de clases antes y después del submuestreo.

Se empleó el mismo esquema de Nested Cross-Validation (5×3) y espacio de hiperparámetros que en el Experimento 1, permitiendo una comparación directa.

Resultados por Fold:

Tabla 30. Resultados por fold del experimento 2.

Fold	Accuracy	Precision	Recall	F1-Score	AUC-ROC
1	0.7802	0.7652	0.6134	0.6809	0.8071
2	0.7633	0.7637	0.5725	0.6544	0.7893
3	0.7650	0.7547	0.5864	0.6600	0.7915
4	0.7697	0.7761	0.5970	0.6748	0.7839
5	0.7559	0.7521	0.5858	0.6586	0.7803
Media	0.7668	0.7623	0.5910	0.6657	0.7904
Desv. Est.	±0.0088	±0.0094	±0.0149	±0.0108	±0.0100

Hiperparámetros óptimos seleccionados por GridSearchCV:

Tabla 31. Hiperparámetros óptimos seleccionados por GridSearchCV del experimento 2.

Fold	C	Penalización	Solver
1	0.1	L1 (Lasso)	liblinear
2	0.1	L1 (Lasso)	liblinear
3	0.1	L1 (Lasso)	liblinear
4	0.1	L2 (Ridge)	liblinear
5	0.1	L1 (Lasso)	liblinear




Figura 23. Métricas de evaluación por fold para el Experimento 2 (con submuestreo).




Figura 24. Panel izquierdo: Matriz de confusión del fold 1 del Exp. 2. Panel derecho: Curva ROC del Exp 2.

Análisis del Experimento 2:

- El Accuracy de 76.68% es más bajo que antes, pero más realista, ya que hay un balance de los “no” y “sí”.
- La Precision se mantiene en 76.23%, incluso ligeramente superior al Exp. 1 (68.06%). El modelo no solo detecta más clientes potenciales, sino que mantiene una tasa de acierto aceptable en sus predicciones positivas.
- El Recall salta de 20.94% a 59.10%: el modelo ahora detecta 3 de cada 5 clientes potenciales, frente a solo 1 de cada 5 en el Exp. 1. Esto representa una mejora.
- El F1-Score mejora de 32.02% a 66.57%, más que duplicándose. Este indicador, que balancea Precision y Recall, confirma que el modelo es más equilibrado y útil para la toma de decisiones.
- El AUC-ROC mejora marginalmente (79.04% vs 78.69%), confirmando que la capacidad discriminativa intrínseca del modelo es estable. La diferencia principal está en la calibración del umbral, no en el poder discriminativo.

12.7 Análisis Comparativo de Experimentos

La siguiente tabla consolida las métricas promedio de ambos experimentos, permitiendo una comparación directa del impacto del balanceo de clases:

Tabla 32. Análisis comparativo de los experimentos.

Métrica	Exp. 1 (Sin Bal.)	Exp. 2 (Con Sub.)	Diferencia	Interpretación
Accuracy	89.98%	76.68%	-13.30 pp	Esperado: se

				reduce al equilibrar clases
Precision	68.06%	76.23%	+8.17 pp	Mejora: predicciones positivas más certeras
Recall	20.94%	59.10%	+38.16 pp	Mejora crítica: detecta más suscriptores
F1-Score	32.02%	66.57%	+34.55 pp	Duplicación: modelo mucho más equilibrado
AUC-ROC	78.69%	79.04%	+0.35 pp	Estable: misma capacidad discriminativa




Figura 25. Comparativa visual de todas las métricas entre ambos experimentos.

Trade-off Accuracy vs Recall:

La reducción de 13 puntos porcentuales en Accuracy es un trade-off deliberado y favorable en el contexto de marketing directo. Un modelo con 90% de Accuracy que solo detecta el 21% de los

clientes potenciales tiene un valor operativo limitado, el coste de oportunidad de perder 4 de cada 5 posibles suscriptores supera ampliamente al coste de contactar algunos falsos positivos adicionales. El Experimento 2, con 77% de Accuracy pero 59% de Recall, es significativamente más útil para la planificación de campañas.

12.8 Evaluación del Modelo

Según los requisitos del proyecto, se evalúa el modelo recomendado (Experimento 2 con submuestreo) utilizando tres métricas básicas:

Precisión (Precision): 76.23%

De todos los clientes que el modelo predice como suscriptores potenciales, el 76.23% efectivamente contrataría el depósito. Esto implica que por cada 4 clientes contactados basándose en la recomendación del modelo, aproximadamente 3 convertirán. Este nivel de precisión genera un retorno positivo sobre la inversión en campañas selectivas.

Sensibilidad (Recall): 59.10%

El modelo identifica correctamente al 59.10% de todos los clientes que realmente contratarían el depósito. Aunque aún se pierden 4 de cada 10 oportunidades, esta tasa es casi tres veces superior a la del modelo sin balanceo (20.94%). En la práctica, el modelo permite capturar más de la mitad de todo el potencial de negocio con contactos dirigidos.

Especificidad (Specificity): calculada a partir de la matriz de confusión

La especificidad mide la proporción de clientes que no contratarían y que el modelo predice correctamente como "no". En el Experimento 2, la especificidad se reduce respecto al Exp. 1 como consecuencia directa del aumento en Recall, el modelo es más "agresivo" en sus predicciones positivas, lo que genera más falsos positivos (clientes contactados innecesariamente) pero captura significativamente más verdaderos positivos (ventas logradas). En el contexto de marketing directo, este es un trade-off óptimo.

12.9 Conclusiones del Modelado Predictivo

Modelo Recomendado:

Se recomienda el modelo del Experimento 2 (Regresión Logística con submuestreo) como herramienta de soporte para la segmentación de campañas. Los hiperparámetros óptimos son $C=0.1$ con penalización L1 (Lasso) y solver liblinear, lo que indica que el modelo se beneficia de una regularización fuerte con selección automática de variables predictoras.

Hallazgos Principales:

- El desbalance de clases (7.87:1) es el factor más determinante en el rendimiento del modelo. Sin tratamiento, la Regresión Logística optimiza la predicción de la clase mayoritaria, haciendo el modelo inútil para detectar clientes potenciales.
- El submuestreo de la clase mayoritaria (pasando de 35.654 “no” a 7.000) mejora drásticamente las métricas relevantes para marketing.
- Las métricas son estables entre folds (desviaciones estándar menor al 2% en todas las métricas), confirmando la robustez del modelo y la validez del esquema de Nested CV.

12.10. Herramienta de predicción de suscripción

A partir del modelo entrenado mediante el experimento 2, el cual incorpora técnicas de submuestreo para el tratamiento del desbalanceo de clases, se ha desarrollado una herramienta interactiva orientada a la predicción de suscripción de clientes potenciales.

Para la construcción de esta herramienta se han seleccionado las variables que presentan mayor poder predictivo dentro del conjunto de datos analizado: nivel de educación (*education_level*), método de contacto (*contact_method*), mes de contacto (*contact_month*), cliente nuevo en campaña (*is_new_campaign_client*) y resultado de campaña previa (*previous_campaign_outcome*). La herramienta ha sido desarrollada mediante el empleo de java script, css y html.

El análisis de importancia de características reveló que estas variables ejercen una influencia determinante en la variabilidad del resultado de suscripción, lo que justifica su inclusión como parámetros de entrada del sistema predictivo.

La interfaz desarrollada permite al usuario introducir los valores correspondientes a cada una de estas variables mediante menús desplegables, facilitando así la interacción con el modelo sin necesidad de conocimientos técnicos avanzados. Una vez configurados los parámetros, el sistema ejecuta la predicción a través del botón "Calcular Predicción" y devuelve una estimación de la probabilidad de suscripción del cliente.

El objetivo principal de esta herramienta es optimizar la asignación de recursos en las campañas de captación, permitiendo identificar de forma anticipada aquellos clientes con mayor propensión a la suscripción. De este modo, se posibilita una gestión más eficiente del tiempo y los recursos comerciales, focalizando los esfuerzos en los prospectos con mayor probabilidad de conversión.

Predicción de Suscripción
Fintech AI score para predicciones de suscripción.

NIVEL DE EDUCACIÓN
No Divulgado

MÉTODO DE CONTACTO
Teléfono

MES DE CONTACTO
Mayo

NUEVO CLIENTE CAMPAÑA
Sí

RESULTADO CAMPAÑA PREVIA
No Existe

Calcular Predicción

Figura 26. Interfaz de la herramienta de predicción desarrollada.

Enlace para acceder a la herramienta:

https://diegoperales065.github.io/marketing_analysis_fintech/

13. Dashboard

13.1. Definición de KPIs

Para evaluar el rendimiento de la campaña se han definido los siguientes indicadores clave:

- **Tasa de conversión (%):** porcentaje de clientes que completan la suscripción sobre el total de contactos realizados.
- **Conversiones totales:** número absoluto de clientes que han realizado la suscripción.
- **Total de clientes:** volumen total de usuarios impactados durante la campaña.

Estos indicadores permiten analizar tanto la eficiencia del proceso de conversión (tasa) como el impacto global de la campaña (volumen), proporcionando una visión completa del rendimiento.

13.2. Estructura del dashboard

El dashboard se ha diseñado siguiendo una estructura clara que facilita su interpretación:

- **Zona superior:** incluye los KPIs principales, permitiendo una visión rápida del rendimiento global.
- **Panel de filtros:** incorpora variables como mes de contacto, perfil financiero, estado civil o rango de edad, lo que permite segmentar el análisis de forma dinámica.

- **Zona central:** contiene las principales visualizaciones analíticas, organizadas por bloques temáticos:
 - Impacto de variables demográficas
 - Situación financiera del cliente
 - Variables operativas (duración de llamada, número de contactos, recencia)
 - Factores económicos externos y patrones temporales

Esta estructura permite combinar una lectura general con un análisis más detallado según las necesidades del usuario.

13.3. Diseño e implementación del Dashboard

Para el diseño de la campaña se ha implementado un dashboard interactivo utilizando Looker Studio, con el objetivo de facilitar la exploración y comprensión de los datos. Este dashboard permite analizar de forma dinámica los factores que influyen en la conversión de clientes, integrando diferentes tipos de visualizaciones y filtros que mejoran la interpretación de los resultados.

En primer lugar, se han utilizado distintas visualizaciones para destacar las tendencias en la efectividad de la campaña a lo largo del tiempo. Mediante gráficos combinados, se analiza la evolución de la tasa de conversión en relación con variables como el Euribor, permitiendo identificar patrones temporales y la influencia del contexto macroeconómico en la toma de decisiones de los clientes.

Además, se han creado gráficos específicos para representar la distribución de variables clave, como el tipo de empleo, la situación financiera, la duración de las llamadas o el número de contactos. Estas visualizaciones permiten identificar de manera clara qué segmentos de clientes presentan mayor probabilidad de conversión y cómo influyen los distintos factores analizados.

Por otro lado, el dashboard incluye indicadores clave de rendimiento (KPIs), como la tasa de conversión, el volumen de clientes y el número de suscripciones, que proporcionan una visión general del desempeño de la campaña.

En conjunto, el uso de visualizaciones interactivas y KPIs facilita la identificación de patrones, tendencias y relaciones entre variables, permitiendo un análisis más eficiente y orientado a la toma de decisiones.




Figura 27. Visión global del dashhoard.

Enlace al dashboard: <https://lookerstudio.google.com/s/v6eWybb9a4Q>

13.4. Visualizaciones

A continuación, se presentan las principales visualizaciones utilizadas en el dashboard, junto con su interpretación:




Figura 28. Gráfica sobre la evolución de la conversión con el paso de los meses y el euríbor.

El análisis del euríbor muestra una relación clara entre el nivel de tipos de interés y la conversión. Los mejores resultados se obtienen en rangos bajos del Euríbor (especialmente entre 0 y 1), donde la tasa de suscripción alcanza aproximadamente casi un 51%.

A medida que el Euríbor aumenta, la conversión disminuye drásticamente, situándose por debajo del 10% en niveles superiores a 3.

Esto indica que los clientes son más propensos a contratar productos financieros en contextos de tipos de interés bajos, mientras que en escenarios de tipos altos muestran mayor resistencia.

Por tanto, el contexto macroeconómico influye de forma significativa en la efectividad de la campaña.




Figura 29. Gráfica sobre la tasa de conversión según el perfil laboral

Este análisis se ha hecho por tipo de empleo y muestra diferencias claras en la tasa de conversión entre los distintos perfiles. Los estudiantes presentan la mayor tasa de suscripción (~31%),

seguidos por los jubilados (~25%), lo que indica que estos grupos tienen una mayor predisposición a contratar el producto.

En niveles intermedios se encuentran perfiles como desempleados y trabajadores administrativos, con tasas en torno al 13–14%. Por el contrario, otros perfiles muestran menor efectividad, lo que evidencia que el tipo de empleo influye en el comportamiento del cliente.

En conjunto, el empleo actúa como un indicador relevante de conversión, aunque no suficiente por sí solo para explicar completamente el éxito de la campaña.




Figura 30. Gráfica de duración de llamada por conversión

La duración de la llamada es uno de los factores más influyentes en la conversión. Se observa que, a medida que aumenta la duración, la probabilidad de suscripción también incrementa la tasa de suscripción hasta un significativamente.

Esto sugiere que las llamadas más largas permiten una mejor explicación del producto y una mayor interacción con el cliente. Sin embargo, esta variable debe interpretarse con cautela, ya que una mayor duración puede ser consecuencia del interés previo del cliente o conocimiento preexistente de la campaña y no necesariamente la causa directa de la conversión.




Figura 31. La gráfica muestra cómo se distribuye la conversión según la duración de la llamada y el perfil financiero del cliente

Se observan diferencias pequeñas pero consistentes entre los distintos perfiles. Los clientes con solo hipoteca presentan la mayor tasa de conversión, seguidos por aquellos que combinan

hipoteca y préstamo, mientras que los clientes sin préstamos y, especialmente, aquellos con solo préstamo personal muestran valores ligeramente inferiores.




Figura 32. Gráfica de clientes antiguos vs. nuevos.

En conjunto, se puede concluir que la situación financiera del cliente tiene un impacto moderado en la conversión. Aunque existen diferencias entre perfiles, estas no son muy pronunciadas, lo que sugiere que otros factores pueden tener un mayor peso en la decisión final de contratación.

Sin embargo, combinar el factor de la duración de la llamada es uno de los factores más influyentes en la conversión. Se observa que, a medida que aumenta la duración, la probabilidad de suscripción también incrementa de manera significativa.

Esto sugiere que las llamadas más largas permiten una mejor explicación del producto y una mayor interacción con el cliente independientemente del perfil financiero.

Se observa que los clientes que han tenido contacto previo con la entidad (no) presentan una mayor probabilidad de conversión. La familiaridad con la empresa y el conocimiento previo del producto reducen la incertidumbre y facilitan la toma de decisión.

En contraste, los clientes nuevos suelen mostrar menores tasas de suscripción.



Figura 33. Gráfica de cantidad de contactos.

El análisis muestra que la mayor tasa de conversión se produce en el primer contacto, alcanzando el valor más alto en comparación con los intentos posteriores. A partir de ese punto, la probabilidad de conversión disminuye progresivamente conforme aumenta el número de contactos.

Esto sugiere que no existe un beneficio en insistir múltiples veces, ya que los clientes más interesados tienden a convertir rápidamente, mientras que aquellos que requieren más contactos presentan menor probabilidad de suscripción.

Por tanto, el primer contacto se identifica como el momento óptimo para maximizar la efectividad de la campaña.




Figura 34. Gráfica de recencia.

Se puede observar que la recencia en los intentos de contacto realmente tiene un impacto positivo en la conversión. Los clientes contactados recientemente presentan mayores tasas de suscripción en comparación con aquellos cuyo último contacto fue hace un tiempo.

Esto indica que mantener una comunicación activa y cercana en el tiempo mejora la efectividad de la campaña.




Figura 35. Gráfica de conversión.

La gráfica muestra la evolución de la tasa de conversión a lo largo de los meses usando filtros como los grupos de edad, estado civil, perfil financiero y el mes de contacto, permitiendo así identificar patrones temporales en la efectividad de la campaña.

Este comportamiento sugiere que no solo el momento del año influye en la predisposición de los clientes a contratar productos financieros, sino muchos factores más.

13.5. Conclusiones y recomendaciones

13.5.1. Conclusiones

El análisis realizado pone de manifiesto que la conversión no depende de un único factor, sino de la interacción de variables demográficas, financieras, operativas y contextuales.

En primer lugar, la segmentación demográfica muestra capacidad explicativa, especialmente cuando se combinan variables como situación laboral, edad y estado civil. Determinados perfiles, como estudiantes, jubilados o jóvenes solteros, presentan una mayor predisposición a la contratación, lo que evidencia la importancia de un enfoque segmentado en la estrategia comercial.

En segundo lugar, la situación financiera del cliente, y en particular la solvencia, se configura como un requisito para la conversión. La ausencia de historial de impagos concentra prácticamente la totalidad de las suscripciones, mientras que el nivel de endeudamiento introduce diferencias más moderadas entre perfiles.

Por otro lado, las variables operativas destacan como uno de los principales drivers de conversión. La duración de la llamada presenta una relación claramente positiva con la probabilidad de éxito, mientras que el número de contactos muestra un efecto inverso, concentrándose la mayor efectividad en el primer intento. Asimismo, la recencia del contacto influye de manera significativa, favoreciendo mayores tasas de conversión en interacciones más recientes.

Además, el conocimiento previo del cliente emerge como un factor clave, ya que la familiaridad con la entidad reduce la incertidumbre y facilita la toma de decisión.

Finalmente, el análisis evidencia que el contexto macroeconómico, representado por el Euribor, condiciona de forma relevante el comportamiento del cliente. En escenarios de tipos de interés bajos se observa una mayor predisposición a la contratación, mientras que en entornos de tipos elevados la conversión disminuye.

En conjunto, los resultados confirman que la conversión es un fenómeno multifactorial, donde la interacción entre variables individuales, operativas y externas determina el rendimiento de la campaña.

13.5.2. Recomendaciones estratégicas

A partir de los hallazgos obtenidos, se proponen las siguientes líneas de actuación orientadas a mejorar la efectividad de la campaña y optimizar el uso de los recursos:

1. Segmentación avanzada y priorización de perfiles

Se recomienda evolucionar hacia una segmentación más precisa que permita identificar y priorizar aquellos perfiles con mayor probabilidad de conversión.

No resulta suficiente aplicar criterios generales; es necesario focalizar los esfuerzos en segmentos específicos que han demostrado un mejor rendimiento, como determinados perfiles demográficos y clientes con una situación financiera sólida.

Asimismo, la solvencia debe integrarse como un criterio clave en la selección de audiencias, priorizando clientes con menor riesgo financiero.

2. Optimización del primer contacto

El primer contacto se configura como el momento crítico de la conversión, por lo que resulta fundamental maximizar su efectividad.

Para ello, se recomienda:

- Reforzar la formación de los agentes en técnicas de comunicación y argumentación.
- Definir guiones estructurados que permitan transmitir de forma clara la propuesta de valor desde el inicio.
- Priorizar la calidad de la interacción frente al volumen de llamadas.

Una ejecución eficiente en esta fase puede tener un impacto directo en los resultados globales de la campaña.

3. Mejora de la calidad de la interacción

Dado el impacto positivo de la duración de la llamada en la conversión, se recomienda fomentar interacciones más completas y personalizadas.

No se trata de aumentar artificialmente la duración, sino de garantizar que el cliente recibe la información necesaria, se resuelven sus dudas y se genera confianza durante la conversación.

4. Gestión eficiente del número de contactos

El análisis evidencia que la insistencia excesiva no mejora la conversión y puede resultar contraproducente.

Por ello, se recomienda:

- Limitar el número de intentos de contacto.
- Establecer estrategias de priorización para centrar los esfuerzos en clientes con mayor probabilidad de conversión.
- Evitar la sobreexposición, que puede generar rechazo.

5. Estrategia basada en la recencia

La recencia del contacto debe integrarse como un elemento clave en la estrategia comercial.

Se recomienda mantener una comunicación continua y bien distribuida en el tiempo, evitando largos periodos sin interacción que puedan reducir el interés del cliente.

6. Fidelización y explotación de clientes existentes

Los clientes con relación previa presentan una mayor probabilidad de conversión, lo que pone de manifiesto el valor de la fidelización.

En este sentido, se recomienda:

- Diseñar campañas específicas para clientes existentes.
- Implementar estrategias de seguimiento y cross-selling.
- Aprovechar la confianza ya establecida para facilitar nuevas contrataciones.

7. Adaptación al contexto macroeconómico

Dado el impacto del entorno económico en la conversión, resulta clave adaptar la estrategia comercial a las condiciones del mercado.

En escenarios de tipos de interés bajos, se recomienda intensificar la actividad comercial, mientras que en contextos más restrictivos puede ser necesario ajustar la propuesta de valor o focalizarse en segmentos más específicos.

8. Optimización temporal de las campañas

La existencia de patrones temporales sugiere la necesidad de planificar la actividad comercial en función de los periodos de mayor efectividad.

Se recomienda analizar de forma continua la evolución de la conversión para identificar los momentos más favorables y concentrar los esfuerzos en dichos periodos.

En conclusión, el presente trabajo demuestra que la conversión en campañas comerciales no responde a un único factor aislado, sino a la interacción compleja entre variables demográficas, financieras, operativas y contextuales. A través del desarrollo de un dashboard interactivo, se ha podido identificar qué perfiles presentan una mayor predisposición a la contratación, así como los principales drivers que condicionan el éxito de la campaña. En particular, la calidad del primer contacto, la recencia de la interacción y el contexto macroeconómico emergen como elementos clave en la toma de decisión del cliente. Estos hallazgos no solo permiten comprender mejor el comportamiento del consumidor, sino que aportan una base sólida para optimizar futuras estrategias comerciales mediante un enfoque basado en datos, segmentación avanzada y eficiencia operativa.

ANEXO 1: ÍNDICE DE FIGURAS

<i>Figura 1. Distribución de edad y duración de llamada con estimación de densidad (KDE), líneas de media y mediana.</i>	8
<i>Figura 2. Distribución de las principales variables categóricas del dataset limpio.</i>	10
<i>Figura 3. Boxplots horizontales de las 5 variables macroeconómicas mostrando cuartiles y distribución.</i>	11
<i>Figura 4. Distribución de la variable target (subscribed) mostrando el ratio de desbalance 7.87:1.</i>	12
<i>Figura 5. Matriz de correlación de Pearson para variables numéricas.</i>	13
<i>Figura 6. Boxplot de distribución de edad por resultado de suscripción.</i>	14
<i>Figura 7. Tasa de conversión por tipo de trabajo, ordenada de menor a mayor. La línea roja discontinua indica la media global (11.28%).</i>	15
<i>Figura 8. Tasa de conversión por nivel educativo.</i>	16
<i>Figura 9. Tasa de conversión por número de intentos de contacto.</i>	18
<i>Figura 10. Panel dual: (izq.) tasa de conversión por mes, (der.) volumen de contactos.</i>	19
<i>Figura 11. Tasa de conversión por día de la semana.</i>	20
<i>Figura 12. Probabilidad de suscripción por grupo de duración de llamada.</i>	21
<i>Figura 13. Tasa de conversión por resultado de la campaña anterior.</i>	22
<i>Figura 14. Comparación de la tasa de conversión entre clientes nuevos y los recurrentes.</i>	23
<i>Figura 15. Violin plots de las 5 variables macroeconómicas vs suscripción.</i>	24
<i>Figura 16. Tasa de conversión por recencia del último contacto.</i>	27
<i>Figura 17. Ranking consolidado de los 10 factores con mayor impacto en la conversión, clasificados por tipo.</i>	28
<i>Figura 18. Distribución de la variable target para modelado.</i>	32
<i>Figura 19. Esquema del proceso de Nested Cross-Validation.</i>	33
<i>Figura 20. Métricas de evaluación por fold para el Experimento 1 (sin balanceo).</i>	35
<i>Figura 21. Panel izquierdo: Matriz de del fold 1 Exp 1. Panel derecho: Curvas ROC del fold 1 Exp 1.</i>	36
<i>Figura 22. Comparación de la distribución de clases antes y después del submuestreo.</i>	37
<i>Figura 23. Métricas de evaluación por fold para el Experimento 2 (con submuestreo).</i>	38
<i>Figura 24. Panel izquierdo: Matriz de confusión del fold 1 del Exp. 2. Panel derecho: Curva ROC del Exp 2.</i>	39
<i>Figura 25. Comparativa visual de todas las métricas entre ambos experimentos.</i>	40
<i>Figura 26. Interfaz de la herramienta de predicción desarrollada.</i>	43
<i>Figura 27. Visión global del dashhoard.</i>	45
<i>Figura 28. Gráfica sobre la evolución de la conversión con el paso de los meses y el euribor.</i>	46
<i>Figura 29. Gráfica sobre la tasa de conversión según el perfil laboral.</i>	46
<i>Figura 30. Gráfica de duración de llamada por conversión.</i>	47
<i>Figura 31. La gráfica muestra cómo se distribuye la conversión según la duración de la llamada y el perfil financiero del cliente.</i>	47

Figura 32. Gráfica de clientes antiguos vs. nuevos.48
Figura 33. Gráfica de cantidad de contactos.48
Figura 34. Gráfica de recencia.49
Figura 35. Gráfica de conversión.49

ANEXO 2: ÍNDICE DE TABLAS

<i>Tabla 1. Stack tecnológico usado en el notebook 1 para la limpieza y exploración de los datos. ..</i>	<i>3</i>
<i>Tabla 2. Clasificación de las variables del dataset.</i>	<i>5</i>
<i>Tabla 3. Métricas observadas y sus resultados.</i>	<i>6</i>
<i>Tabla 4. Categorización de la duración de la llamada.</i>	<i>7</i>
<i>Tabla 5. Nuevas variables creadas a partir de las existentes.</i>	<i>7</i>
<i>Tabla 6. Descripción estadística de las variables numéricas del dataset.</i>	<i>8</i>
<i>Tabla 7. Descripción estadística de las variables categóricas del dataset.</i>	<i>10</i>
<i>Tabla 8. Variable target del dataset.</i>	<i>12</i>
<i>Tabla 9. Correlación de las variables macroeconómicas.</i>	<i>13</i>
<i>Tabla 10. Relación entre la edad y la suscripción.</i>	<i>14</i>
<i>Tabla 11. Relación entre el tipo de trabajo y la suscripción.</i>	<i>15</i>
<i>Tabla 12. Relación entre la educación y la suscripción.</i>	<i>16</i>
<i>Tabla 13. Relación entre el estado civil y la suscripción.</i>	<i>17</i>
<i>Tabla 14. Relación entre el crédito de incumplimiento y la suscripción.</i>	<i>17</i>
<i>Tabla 15. Relación entre la hipoteca y préstamo personal y la suscripción.</i>	<i>17</i>
<i>Tabla 16. Relación entre el número de contactos y la suscripción.</i>	<i>18</i>
<i>Tabla 17. Relación entre el mes de contacto y la suscripción.</i>	<i>19</i>
<i>Tabla 18. Relación entre el día de la semana de contacto y la suscripción.</i>	<i>20</i>
<i>Tabla 19. Relación entre la duración de la llamada y la suscripción.</i>	<i>21</i>
<i>Tabla 20. Relación entre el método de contacto y la suscripción.</i>	<i>22</i>
<i>Tabla 21. Relación entre el resultado de la campaña previa y la suscripción.</i>	<i>22</i>
<i>Tabla 22. Relación entre si es un nuevo cliente o no y la suscripción.</i>	<i>23</i>
<i>Tabla 23. Relación entre las variables macroeconómicas y la suscripción.</i>	<i>24</i>
<i>Tabla 24. Segmentos de alta conversión.</i>	<i>25</i>
<i>Tabla 25. Segmentos de bajo rendimiento.</i>	<i>26</i>
<i>Tabla 26. Ranking de factores.</i>	<i>29</i>
<i>Tabla 27. Hiperparámetros utilizados.</i>	<i>34</i>
<i>Tabla 28. Resultados por fold del experimento 1.</i>	<i>34</i>
<i>Tabla 29. Hiperparámetros óptimos seleccionados por GridSearchCV del experimento 1.</i>	<i>35</i>
<i>Tabla 30. Resultados por fold del experimento 2.</i>	<i>37</i>
<i>Tabla 31. Hiperparámetros óptimos seleccionados por GridSearchCV del experimento 2.</i>	<i>38</i>
<i>Tabla 32. Análisis comparativo de los experimentos.</i>	<i>39</i>